

Преподаватель:

Министерство образования и науки Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

Методы машинного обучения

Отчёт по лабораторной работе № 6

«Ансамбли моделей машинного обучения»

Выполнил: студент группы ИУ5 – 23М Крутов Т.Ю.

Гапанюк Ю.Е.

```
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from scipy import stats
from IPython.display import Image
from sklearn.externals.six import StringIO
from IPython.display import Image
import graphviz
import pydotplus
from sklearn.datasets import load iris, load boston
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.model_selection import GridSearchCV, RandomizedSearchCV
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score, classification_report
from sklearn.metrics import confusion_matrix
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graphviz
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.ensemble import ExtraTreesClassifier, ExtraTreesRegressor
from sklearn.ensemble import GradientBoostingClassifier, GradientBoostingRegressor
from sklearn.ensemble import BaggingClassifier
from sklearn.ensemble import AdaBoostClassifier
from sklearn.metrics import mean_absolute_error, mean_squared_error, mean_squared_log_erro
from sklearn.metrics import roc_curve, roc_auc_score
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
%matplotlib inline
sns.set(rc={'figure.figsize':(16,8)})
    /usr/local/lib/python3.6/dist-packages/sklearn/externals/six.py:31: FutureWarning: Th
       "(<a href="https://pypi.org/project/six/">https://pypi.org/project/six/</a>).", FutureWarning)
df = pd.read_csv('titanic.csv', error_bad_lines=False, comment='#')
#df.drop(columns='id', inplace = True);
df.drop(columns='Cabin', inplace= True)
for col in df.columns:
    count = df[df[col].isnull()].shape[0]
    print('{} - {}'.format(col, count))
print ('{} - размер датасета'.format(df.shape))
 Гэ
```

```
PassengerId - 0
Survived - 0
Pclass - 0
Name - 0

df = df.dropna(axis=0, how='any')
(df.shape)

[> (712, 11)
Fare - 0

df.drop(columns=['Ticket', 'Name'], inplace= True)
df.reset_index(drop= True, inplace=True)
df
```

₽		PassengerId	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
	0	1	0	3	male	22.0	1	0	7.2500	S
	1	2	1	1	female	38.0	1	0	71.2833	С
	2	3	1	3	female	26.0	0	0	7.9250	S
	3	4	1	1	female	35.0	1	0	53.1000	S
	4	5	0	3	male	35.0	0	0	8.0500	S
	707	886	0	3	female	39.0	0	5	29.1250	Q
	708	887	0	2	male	27.0	0	0	13.0000	S
	709	888	1	1	female	19.0	0	0	30.0000	S
	710	890	1	1	male	26.0	0	0	30.0000	С
	711	891	0	3	male	32.0	0	0	7.7500	Q

712 rows × 9 columns

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
le = LabelEncoder()
ohe = OneHotEncoder()
sex = le.fit_transform(df['Sex'])
sex = pd.DataFrame({'Sex':sex.T})
Embarked = le.fit_transform(df['Embarked'])
Embarked = pd.DataFrame({'Embarked' : Embarked.T })
sex
```

С→

	Sex
0	1
1	0
2	0
3	0
4	1
707	0

del df['Sex']
del df['Embarked']
df = df.join(sex)
df = df.join(Embarked)
df

₽		PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare	Sex	Embarked
	0	1	0	3	22.0	1	0	7.2500	1	2
	1	2	1	1	38.0	1	0	71.2833	0	0
	2	3	1	3	26.0	0	0	7.9250	0	2
	3	4	1	1	35.0	1	0	53.1000	0	2
	4	5	0	3	35.0	0	0	8.0500	1	2
	707	886	0	3	39.0	0	5	29.1250	0	1
	708	887	0	2	27.0	0	0	13.0000	1	2
	709	888	1	1	19.0	0	0	30.0000	0	2
	710	890	1	1	26.0	0	0	30.0000	1	0
	711	891	0	3	32.0	0	0	7.7500	1	1


712 rows × 9 columns

```
X = df.drop(columns='Survived')
y = df.Survived

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2)
bc1 = BaggingClassifier(n_estimators=5, oob_score=True, random_state=10)
bc1.fit(X_train, y_train)
```

С→

```
/usr/local/lib/python3.6/dist-packages/sklearn/ensemble/_bagging.py:633: UserWarning:
       warn("Some inputs do not have OOB scores. "
     /usr/local/lib/python3.6/dist-packages/sklearn/ensemble/_bagging.py:638: RuntimeWarni
       predictions.sum(axis=1)[:, np.newaxis])
     BaggingClassifier(base_estimator=None, bootstrap=True, bootstrap_features=False,
                       max features=1.0, max samples=1.0, n estimators=5,
bc1.estimators_samples_
# Сконвертируем эти данные в двоичную матрицу,
# 1 соответствует элементам, попавшим в обучающую выборку
bin_array = np.zeros((5, X.shape[0]))
for i in range(5):
    for j in bc1.estimators_samples_[i]:
        bin_array[i][j] = 1
bin_array
 \rightarrow array([[1., 0., 0., ..., 1., 0., 1.],
            [0., 1., 1., ..., 1., 1., 0.],
            [1., 1., 0., ..., 0., 1., 1.],
            [1., 0., 1., ..., 1., 0., 1.],
            [0., 1., 1., ..., 0., 0., 1.]]
# И визуализируем (синим цветом показаны данные, которые попали в обучающую выборку)
fig, ax = plt.subplots(figsize=(12,2))
ax.pcolor(bin_array, cmap='YlGnBu')
plt.show()
 Гэ
                   100
                                200
                                            300
                                                         400
                                                                     500
                                                                                  600
# Оценим Out-of-bag error, теоретическое значение 37%
for i in range(5):
    cur_data = bin_array[i]
    len cur data = len(cur data)
    sum cur data = sum(cur data)
    (len(bin_array[0]) - sum(bin_array[0])) / len(bin_array[0])
    oob_i = (len_cur_data - sum_cur_data) / len_cur_data
    print('Для модели № {} размер ООВ составляет {}%'.format(i+1, round(oob i, 4)*100.0))
 Г→ Для модели № 1 размер ООВ составляет 35.67%
     Для модели № 2 размер ООВ составляет 36.52%
     Для модели № 3 размер ООВ составляет 37.22%
     Для модели № 4 размер ООВ составляет 37.36%
     Для модели № 5 размер ООВ составляет 38.9%
# Визуализация обученных решающих деревьев
Image(get_png_tree(bc1.estimators_[0], y[:8]), width="500")
```



Случайный лес

```
from sklearn.ensemble import AdaBoostClassifier, BaggingClassifier, RandomForestClassifier
clf_rf = RandomForestClassifier(n_estimators=5, max_depth=15)
clf_rf.fit(X_train, y_train)
```

RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None, criterion='gini', max_depth=15, max_features='auto', max_leaf_nodes=None, max_samples=None, min_impurity_decrease=0.0, min_impurity_split=None, min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0, n_estimators=5, n_jobs=None, oob_score=False, random_state=None, verbose=0, warm start=False)

```
from sklearn.metrics import f1_score as f1_sc, accuracy_score as accuracy print('accuracy_score для обучающего набора:', accuracy(y_train, clf_rf.predict(X_train))) print('accuracy_score для тестового набора:', accuracy(y_test, clf_rf.predict(X_test)), 'print('f1_score для обучающего набора:', f1_sc(y_train, clf_rf.predict(X_train))) print('f1_score для тестового набора:', f1_sc(y_test, clf_rf.predict(X_test)), '\n')
```

□ ассигасу_score для обучающего набора: 0.961335676625659 ассигасу_score для тестового набора : 0.7902097902097902

f1_score для обучающего набора: 0.9521739130434783 f1 score для тестового набора: 0.72222222222222

→ BaggingClassifier

```
clf_bc = BaggingClassifier(n_estimators=1)
clf_bc.fit(X_train, y_train)
```

print('accuracy_score для обучающего набора:', accuracy(y_train, clf_bc.predict(X_train)))

```
print('accuracy_score для тестового набора:', accuracy(y_test, clf_bc.predict(X_test)), 'print('f1_score для обучающего набора:', f1_sc(y_train, clf_bc.predict(X_train)))
print('f1_score для тестового набора:', f1_sc(y_test, clf_bc.predict(X_test)), '\n')

□ accuracy_score для обучающего набора: 0.8892794376098418
accuracy_score для тестового набора: 0.7832167832167832

f1_score для обучающего набора: 0.8656716417910448
f1_score для тестового набора: 0.7394957983193278
```

▼ Подбор гиперпараметров с помощью GridSearchCV

```
from sklearn.model_selection import GridSearchCV
params = {'n_estimators' : np.arange(1, 50, 1),
          'max_depth' : np.arange(3, 10, 1)}
grcrch = GridSearchCV(estimator=RandomForestClassifier(), param_grid=params)
grcrch.fit(X_train, y_train)
 GridSearchCV(cv=None, error_score=nan,
                  estimator=RandomForestClassifier(bootstrap=True, ccp_alpha=0.0,
                                                   class_weight=None,
                                                   criterion='gini', max_depth=None,
                                                   max_features='auto',
                                                   max_leaf_nodes=None,
                                                   max_samples=None,
                                                   min_impurity_decrease=0.0,
                                                   min_impurity_split=None,
                                                   min_samples_leaf=1,
                                                   min_samples_split=2,
                                                   min_weight_fraction_leaf=0.0,
                                                   n_estimators=100, n_jobs=No...
                                                   random_state=None, verbose=0,
                                                   warm_start=False),
                  iid='deprecated', n jobs=None,
                  param_grid={'max_depth': array([3, 4, 5, 6, 7, 8, 9]),
                               'n_estimators': array([ 1,  2,  3,  4,  5,  6,  7,  8,  9,  1
            18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34,
            35, 36, 37, 38, 39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49])},
                  pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
                  scoring=None, verbose=0)
grcrch.best_params_
 [→ {'max_depth': 6, 'n_estimators': 33}
print('accuracy_score для обучающего набора:', accuracy(y_train, grcrch.best_estimator_.pr
print('accuracy_score для тестового набора :', accuracy(y_test, grcrch.best_estimator_.pre
print('f1_score для обучающего набора:', f1_sc(y_train, grcrch.best_estimator_.predict(X_t
print('f1_score для тестового набора :', f1_sc(y_test, grcrch.best_estimator_.predict(X_te
```

```
accuracy score для обучающего набора: 0.8822495606326889
     accuracy score для тестового набора : 0.8391608391608392
     f1 score для обучающего набора: 0.8416075650118203
params = {'n_estimators' : np.arange(1, 30, 1)}
grcrch = GridSearchCV(estimator=AdaBoostClassifier(), param_grid=params)
grcrch.fit(X_train, y_train)
 GridSearchCV(cv=None, error_score=nan,
                  estimator=AdaBoostClassifier(algorithm='SAMME.R',
                                               base_estimator=None,
                                               learning_rate=1.0, n_estimators=50,
                                               random_state=None),
                  iid='deprecated', n_jobs=None,
                  param grid=\{ 'n \text{ estimators'} : array([1, 2, 3, 4, 5, 6, 7, 8, 9, 1 ] \} \}
            18, 19, 20, 21, 22, 23, 24, 25, 26, 27, 28, 29])},
                  pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
                  scoring=None, verbose=0)
grcrch.best_estimator_
 ☐→ AdaBoostClassifier(algorithm='SAMME.R', base_estimator=None, learning_rate=1.0,
                        n_estimators=12, random_state=None)
print('accuracy_score для обучающего набора:', accuracy(y_train, grcrch.best_estimator_.pr
print('accuracy_score для тестового набора :', accuracy(y_test, grcrch.best_estimator_.pre
print('f1_score для обучающего набора:', f1_sc(y_train, grcrch.best_estimator_.predict(X_t
print('f1_score для тестового набора :', f1_sc(y_test, grcrch.best_estimator_.predict(X_te
 □→ accuracy_score для обучающего набора: 0.8822495606326889
     accuracy score для тестового набора: 0.8391608391608392
     f1 score для обучающего набора: 0.8416075650118203
     f1 score для тестового набора : 0.7628865979381443
```

▼ Как можно заметить, что после побора гиперпараметров методом GridSearchCV метрики ка

```
def make_meshgrid(x, y, h=.02):
    """Create a mesh of points to plot in

Parameters
------
x: data to base x-axis meshgrid on
y: data to base y-axis meshgrid on
h: stepsize for meshgrid, optional

Returns
-----
xx, yy : ndarray
```

```
x_{min}, x_{max} = x.min() - 1, x.max() + 1
    y_{min}, y_{max} = y.min() - 1, y.max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                         np.arange(y_min, y_max, h))
    return xx, yy
def plot_contours(ax, clf, xx, yy, **params):
    """Plot the decision boundaries for a classifier.
    Parameters
    -----
    ax: matplotlib axes object
    clf: a classifier
    xx: meshgrid ndarray
    yy: meshgrid ndarray
    params: dictionary of params to pass to contourf, optional
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)
    #Можно проверить все ли метки классов предсказываются
    #print(np.unique(Z))
    out = ax.contourf(xx, yy, Z, **params)
    return out
def plot_cl(clf):
    title = clf.__repr__
    clf.fit(X, y)
    fig, ax = plt.subplots(figsize=(5,5))
    X0, X1 = X[:, 0], y[:, 1]
    xx, yy = make_meshgrid(X0, X1)
    plot_contours(ax, clf, xx, yy, cmap=plt.cm.coolwarm, alpha=0.8)
    ax.scatter(X0, X1, c=iris_y, cmap=plt.cm.coolwarm, s=20, edgecolors='k')
    ax.set_xlim(xx.min(), xx.max())
    ax.set_ylim(yy.min(), yy.max())
    ax.set_xlabel('Sepal length')
    ax.set_ylabel('Sepal width')
    ax.set_xticks(())
    ax.set_yticks(())
    ax.set_title(title)
    plt.show()
    from operator import itemgetter
def draw_feature_importances(tree_model, X_dataset, figsize=(10,5)):
    Вывод важности признаков в виде графика
    # Сортировка значений важности признаков по убыванию
    list to sort = list(zip(X dataset.columns.values, tree model.feature importances ))
    sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse = True)
    # Названия признаков
    labels = [x for x,_ in sorted_list]
    # Важности признаков
    data = [x for _,x in sorted_list]
```

```
# вывод графика
    fig, ax = plt.subplots(figsize=figsize)
    ind = np.arange(len(labels))
    plt.bar(ind, data)
    plt.xticks(ind, labels, rotation='vertical')
    # Вывод значений
    for a,b in zip(ind, data):
        plt.text(a-0.05, b+0.01, str(round(b,3)))
    plt.show()
    return labels, data
# Визуализация дерева
def get_png_tree(tree_model_param, feature_names_param):
    dot_data = StringIO()
    export_graphviz(tree_model_param, out_file=dot_data, feature_names=feature_names_param
                    filled=True, rounded=True, special_characters=True)
    graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
    return graph.create_png()
```